

# Agentes Autônomos – Reasoning (Estratégias Cognitivas em LLMs)

## 1. Nome do Grupo

GRUPO\_5

## 2. Participantes

Nome Completo	Telefone	E-mail	Contribuiu com a Atividade?
Carlos Magno Marcelino	+55 11 98949-8106	cmmarcelinus@gmail.com	<input checked="" type="checkbox"/> Sim
Ewerton	+55 22 98870-9994	bomsensoink@gmail.com	<input checked="" type="checkbox"/> Sim
Luis Antônio	+55 69 99260-4163	luisantoniocostaneto@gmail.com	<input checked="" type="checkbox"/> Sim
Vivian	+55 11 98488-2650	vivian.ruiz74@gmail.com	<input checked="" type="checkbox"/> Sim
Ivan	+55 63 98121-0234		<input type="checkbox"/> Não
Márcio Ferreira	+55 66 99910-4231		<input type="checkbox"/> Não
Martins	+244 932 964 743		<input type="checkbox"/> Não

**Nota:** Algumas das análises e exemplos incluídos nesta versão do relatório foram enriquecidos com base em contribuições adicionais dos colegas de equipe. O conteúdo colaborativo fortaleceu a compreensão das estratégias cognitivas envolvidas na atuação de agentes autônomos.

## 3. Estratégias de Raciocínio com LLMs (Large Language Models)

Com o avanço da Inteligência Artificial, as LLMs (Modelos de Linguagem de Grande Escala) têm sido capazes de simular raciocínio através de **estratégias específicas de aprendizado e inferência**, e não apenas por tipos lógicos clássicos como dedução ou indução.

Nesta seção, abordamos as **principais estratégias cognitivas usadas por LLMs para raciocinar**, resolver problemas e gerar respostas coerentes, relevantes e adaptativas.

### 3.1 In-Context Learning (ICL)

- **Descrição:** A LLM aprende temporariamente a partir do próprio prompt fornecido, sem ajustes no modelo. Ou seja, ela "observa" exemplos no momento da interação e usa isso para generalizar.
- **Exemplo prático:** Se fornecermos 3 exemplos de como classificar notas fiscais por CFOP e pedirmos a classificação de um quarto, a LLM consegue inferir o padrão com base apenas no contexto.
- **Aplicação fiscal:** Treinamento ad hoc com regras e exceções de documentos fiscais no próprio prompt, sem reprogramação do modelo.

## Variações do In-Context Learning

O In-Context Learning pode ser aplicado em três níveis, de acordo com a quantidade de exemplos fornecidos:

- **Zero-Shot Learning:** A LLM resolve a tarefa sem qualquer exemplo anterior, baseando-se apenas na descrição da tarefa.  
*Exemplo:* "Explique o que significa o CFOP 5.102."
  - **One-Shot Learning:** Um único exemplo é fornecido antes da tarefa principal.  
*Exemplo:* Traduzir um campo de nota fiscal após ver apenas uma tradução anterior no mesmo estilo.
  - **Few-Shot Learning:** Dois a cinco exemplos são incluídos no prompt para ensinar um padrão desejado.  
*Exemplo:* Mostrar três notas fiscais com CFOPs corretos e incorretos antes de pedir a classificação de uma nova nota.
- 

### 3.2 Zero-shot Learning

- **Descrição:** A LLM tenta resolver uma tarefa **sem exemplos prévios**, confiando apenas em sua base de conhecimento e interpretação do enunciado.
  - **Exemplo prático:** "Explique por que o CFOP 5.102 está incorreto em uma nota de devolução."
  - **Aplicação fiscal:** Ideal para sistemas autônomos que respondem a dúvidas fiscais pontuais sem histórico de treinamento local.
- 

### 3.3 Few-shot Learning

- **Descrição:** A LLM recebe **poucos exemplos no prompt** para entender o padrão desejado antes de gerar uma resposta.
  - **Exemplo prático:** Apresentar dois ou três erros comuns de ICMS e pedir à IA para identificar se uma nova nota apresenta erro similar.
  - **Aplicação fiscal:** Útil para treinar agentes sobre regras contábeis específicas com base em poucos casos reais ou simulados.
- 

### 3.4 Chain-of-Thought (CoT) Prompting

- **Descrição:** Estimula a LLM a "pensar em voz alta", explicando passo a passo o raciocínio antes de chegar à resposta final.
  - **Exemplo prático:** Ao invés de responder diretamente se um CFOP está correto, a IA lista as regras envolvidas, verifica o estado, a operação, o tipo de contribuinte, e só depois conclui.
  - **Aplicação fiscal:** Reforça a transparência e auditabilidade das decisões automatizadas por IA.
-

### 3.5 Fine-tuning

- **Descrição:** Treinamento especializado da LLM com um novo conjunto de dados para ajustar permanentemente seu comportamento.
  - **Exemplo prático:** Treinar a IA com notas fiscais reais da empresa para que ela aprenda os padrões específicos de operação, erros recorrentes e regras locais.
  - **Aplicação fiscal:** Ideal para empresas que querem criar um "consultor fiscal interno" com a linguagem e práticas próprias da organização.
- 

### 3.6 Retrieval-Augmented Generation (RAG)

- **Descrição:** A LLM consulta fontes externas (como bases de dados, documentos, sistemas ERP) para gerar respostas fundamentadas e atualizadas.
  - **Exemplo prático:** A IA acessa a tabela de CFOP do CONFAZ ou um banco de XMLs reais da empresa para validar um documento automaticamente.
  - **Aplicação fiscal:** Fortalece a confiabilidade e atualização das respostas geradas, alinhando a IA ao ambiente contábil em tempo real.
- 

### 3.7 ReAct (Reasoning + Acting)

- **Descrição:** A LLM combina raciocínio com ações externas, como executar scripts ou tomar decisões com base em fluxos de automação.
  - **Exemplo prático:** Identificar erro em CFOP, consultar nota de origem e automaticamente preencher o campo correto ou gerar um alerta.
  - **Aplicação fiscal:** Muito útil para sistemas inteligentes com autonomia para "decidir e agir" no processamento de documentos.
- 

### 3.8 Rationale Engineering (Engenharia de Justificativa)

- **Descrição:** Técnica que força a LLM a apresentar justificativas claras para cada resposta, promovendo rastreabilidade, auditabilidade e explicações mais confiáveis.

- **Exemplo aplicado:**

Pergunta: "Classifique o seguinte comentário de cliente como positivo, negativo ou neutro: 'A entrega foi rápida, mas o produto veio errado.'"

Resposta com rationale:

"O comentário mistura pontos positivos (entrega rápida) e negativos (produto errado), mas o erro no item vendido compromete mais a satisfação. **Classificação: Negativo.**"

- **Aplicação fiscal:**

Essa abordagem pode ser utilizada em validações fiscais onde a IA precisa justificar:

- Por que um CFOP está incorreto;
  - Por que um imposto está mal calculado;
  - Por que um CST é incompatível com a operação registrada.
-

Essas estratégias permitem que LLMs não apenas gerem texto, mas **resolvam problemas, identifiquem padrões, adaptem-se ao contexto e tomem decisões coerentes** em tarefas contábeis e fiscais. O próximo passo é testar cada uma delas em cenários práticos e avaliar seu desempenho.

## 4. Testes Práticos com Estratégias de Raciocínio

### 4.1 Cenário Geral

Para validar a aplicação das estratégias de raciocínio pelas LLMs no contexto fiscal, realizamos testes com três modelos: **ChatGPT (GPT-4o)**, **Gemini Flash 2.0** e **Grok**. O objetivo foi observar como cada modelo responde a tarefas fiscais aplicando uma estratégia distinta, como **zero-shot learning**, **few-shot learning**, **chain-of-thought prompting** e **in-context learning**.

Abaixo, apresentamos os testes aplicados e a análise de desempenho de cada modelo.

### 4.2 Testes e Resultados

#### Estratégia: Zero-Shot Learning

- **Descrição:** A LLM tenta resolver a tarefa apenas com base na sua base de conhecimento, sem nenhum exemplo prévio no prompt.
- **Prompt utilizado:** *"Explique por que o CFOP 5.102 está incorreto em uma nota de devolução de mercadoria adquirida de terceiros, com operação interna."*
- **Modelos utilizados e resultados:**
  - **ChatGPT:** Resposta direta e correta, identificando o uso incorreto do CFOP e sugerindo 5.202 como alternativa.
  - **Gemini:** Resposta fundamentada com citação da tabela de CFOP e menção à possibilidade de rejeição pela SEFAZ.
  - **Grok:** Resposta densa, mas precisa, com explicação legal e referência ao contexto tributário.
- **Análise:** Todos os modelos conseguiram resolver a tarefa sem exemplos. A estratégia se mostrou eficaz para **validação fiscal baseada em regras claras**.

#### Exemplo Complementar – Classificação com Justificativa

**Tarefa aplicada:**

"Analisar o seguinte cenário: uma nota fiscal apresenta CFOP 5.102 em uma devolução de mercadoria adquirida de terceiros. Esse CFOP está correto?"

**Resposta gerada com justificativa (Rationale):**

"O CFOP 5.102 é utilizado para vendas de mercadoria adquirida de terceiros. Como se trata de uma devolução, o CFOP adequado seria 5.202. Portanto, o código está incorreto. **Classificação: Incorreto.**"

**Estratégia aplicada:** Rationale Engineering + Zero-Shot

### Estratégia: Few-Shot Learning

- **Descrição:** São fornecidos alguns exemplos antes da pergunta principal para ajudar a LLM a entender o padrão desejado.
- **Prompt utilizado (resumo):** Exemplo 1: Nota fiscal com CFOP 5.101 – operação correta (venda interna de produção própria).  
Exemplo 2: Nota com CFOP 6.101 usada para venda interna – operação incorreta.  
Exemplo 3: Nota de devolução com CFOP 5.202 – operação correta.

Pergunta: Uma nota de devolução apresenta CFOP 5.102. Está correta?

- **Modelos utilizados e resultados:**
  - **ChatGPT:** Aplicou bem os exemplos e respondeu corretamente, explicando com base no padrão apresentado.
  - **Gemini:** Identificou o erro e justificou com base nos exemplos, reforçando a necessidade de validar a natureza da operação.
  - **Grok:** Utilizou os exemplos para estruturar a resposta e indicou o CFOP 5.202 como alternativa correta.
  - **Análise:** A few-shot learning ajudou a reforçar o padrão desejado. Os modelos demonstraram boa capacidade de **raciocínio a partir de casos similares**, o que simula bem situações reais.
- 

### Estratégia: Chain-of-Thought (CoT) Prompting

- **Descrição:** A IA é incentivada a “pensar em voz alta”, explicando passo a passo como chegou à resposta.
  - **Prompt utilizado:** *"Sabemos que CFOPs iniciados por 5 indicam operações internas. A nota apresenta CFOP 6.101. Explique passo a passo se essa operação está correta para uma venda interna a consumidor final."*
  - **Modelos utilizados e resultados:**
  - **ChatGPT:** Quebrou o raciocínio em premissas, análise do código, interpretação fiscal e conclusão.
  - **Gemini:** Organizou em etapas: tipo de CFOP, operação descrita, operação real, conflito e conclusão.
  - **Grok:** Utilizou formato argumentativo lógico, trazendo explicação do código, origem do erro e recomendação.
  - **Análise:** Essa estratégia foi a que apresentou **respostas mais ricas e justificadas**, sendo ideal para agentes fiscais transparentes e auditáveis.
- 

### Estratégia: In-Context Learning

- **Descrição:** A LLM aprende a partir do próprio contexto da conversa anterior ou de exemplos embutidos no mesmo prompt.

- **Cenário utilizado:** Durante a interação, fornecemos uma série de erros em notas fiscais anteriores (CFOPs, CSTs, ICMS) e, ao final, perguntamos: *"Com base nas ocorrências acima, como o sistema poderia reagir automaticamente ao detectar uma nova nota com CFOP 5.102 em uma devolução?"*
- **Modelos utilizados e resultados:**
- **ChatGPT:** Sugeriu alertas automáticos, bloqueios e substituição do CFOP com base no padrão anterior.
- **Gemini:** Relembrou o contexto e aplicou lógica adaptativa, sugerindo correção automática.
- **Grok:** Aplicou abordagem baseada em caso anterior (CBR + contexto), sugerindo ações proativas.
- **Análise:** O contexto prévio foi bem assimilado por todos os modelos, demonstrando que **a IA pode "aprender" no diálogo** e adaptar-se a padrões recorrentes.

4.3 Comparativo entre Estratégias

Estratégia	Vantagens	Desvantagens	Aplicação ideal
Zero-Shot	Rápida, direta, sem necessidade de exemplos	Pode falhar com tarefas ambíguas ou complexas	Respostas pontuais e diretas
Few-Shot	Melhora acurácia com pouco esforço adicional	Depende de bons exemplos	Classificação, validação baseada em padrões
Chain-of-Thought	Garante transparência, rastreabilidade e lógica clara	Respostas mais longas	Auditoria, explicações regulatórias
In-Context Learning	Adaptação a padrões específicos durante o uso	Sensível à ordem e clareza do prompt	Agentes com "memória de sessão"

5. Conclusão

A atividade proposta nos levou a estudar e testar as **estratégias de raciocínio utilizadas por LLMs (Large Language Models)** em tarefas de análise e automação fiscal. Em vez de abordagens tradicionais (dedução, indução, abdução), exploramos como os modelos aplicam métodos modernos como **zero-shot learning**, **few-shot learning**, **in-context learning**, **chain-of-thought prompting**, entre outros.

A partir dos testes práticos com modelos como **ChatGPT (GPT-4o)**, **Gemini Flash 2.0** e **Grok**, observamos que:

- Cada estratégia tem pontos fortes em diferentes contextos:
  - **Zero-shot** é excelente para respostas diretas com base no conhecimento geral do modelo.
  - **Few-shot** oferece maior precisão ao seguir padrões observados.
  - **CoT (Chain-of-Thought)** se destacou por gerar explicações claras e rastreáveis, ideais para agentes auditáveis.
  - **In-context learning** demonstrou capacidade de adaptação ao cenário, assimilando padrões e aplicando soluções com base no próprio histórico da conversa.
- As LLMs foram eficazes ao:

- Identificar erros comuns em CFOP e CST;
- Diagnosticar valores incoerentes de ICMS;
- Sugerir correções automatizadas e fluxos de validação.

Esse tipo de raciocínio estratégico é essencial para construir **agentes fiscais autônomos inteligentes**, que não apenas validam regras, mas **aprendem com os dados, justificam decisões e interagem de forma contextualizada** com usuários e sistemas contábeis.

O estudo reforça que a adoção dessas estratégias pode reduzir erros manuais, acelerar rotinas fiscais e apoiar a transformação digital do setor contábil com uso ético e inteligente da IA generativa.

Com base nos resultados obtidos, o grupo entende que o uso combinado dessas estratégias pode compor um sistema robusto de agentes autônomos aplicados ao setor fiscal. Recomendamos a continuidade do projeto com testes reais em ambientes controlados, explorando especialmente a integração com bases de dados e automação de processos contábeis.

---

## 6. Referências Bibliográficas

- Curso de Inteligência Artificial e Agentes Autônomos – Aula de 15/05/2025
- OpenAI. [ChatGPT GPT-4o]. Disponível em: <https://chat.openai.com>
- Google. [Gemini Flash 2.0]. Disponível em: <https://gemini.google.com>
- XAI. [Grok AI]. Plataforma de testes via navegador
- Brown et al. (2020). "Language Models are Few-Shot Learners" – Paper original do GPT-3
- Wei et al. (2022). "Chain-of-Thought Prompting Elicits Reasoning in Large Language Models"
- OpenAI Documentation – <https://platform.openai.com/docs>
- Google DeepMind Blog – Estratégias de In-Context Learning
- Tabela de CFOP – CONFAZ
- Ajuste SINIEF 01/2024 – Normas de emissão de NF-e e CFOP